

Vous trouverez ci-dessous un article publié en 2019 (disponible en format PDF sur Moodle) :
 Bercu, B., Capderou, S., & Durrieu, G. (2019). Nonparametric recursive estimation of the derivative of the regression function with application to sea shores water quality. *Statistical Inference for Stochastic Processes*, 22(1), 17-40.

Nous considérons dans cet article le modèle à design aléatoire définie, pour tout $n \geq 1$, par

$$Y_n = f(X_n) + \varepsilon_n$$

où

- (X_n) est une suite de variables aléatoires indépendantes et identiquement distribuées de densité de probabilité g ,
- (ε_n) est une suite de variables aléatoires indépendante de (X_n) , telle que $\mathbb{E}(\varepsilon_n) = 0$ et $\mathbb{E}(\varepsilon_n^2) = \sigma^2$,
- la fonction de régression, notée par f , est supposée inconnue et la densité $g \in \mathcal{C}_b^2(\mathbb{R})$ (dérivées bornées).

Dans cet article, trois estimateurs $\hat{f}'_n(x)$, $\tilde{f}'_n(x)$ et $\check{f}'_n(x)$ de la dérivée $f'(x)$ de la fonction $f(x)$ sont proposés. Ils correspondent respectivement aux expressions (9), (10) et (11) de la publication.

1. Implémenter, sous R, trois fonctions dédiées au calcul de chacun de ces trois estimateurs de la dérivée de la fonction f .
2. Fournir les codes R permettant de réaliser les simulations présentées dans le paragraphe 4 “Simulated Data”, afin d’illustrer numériquement :
 - (a) la convergence presque sûre des trois estimateurs $\hat{f}'_n(x)$, $\tilde{f}'_n(x)$ et $\check{f}'_n(x)$ de la dérivée $f'(x)$ présentés dans le Théorème 3.1. Donner le code R permettant la représentation graphique de la Figure 1 de l’article.
 - (b) le théorème central limite énoncé dans le Théorème 3.2. Vous donnerez les codes R permettant les représentations graphiques de la Figure 2 de l’article correspondant à la distribution des 3 estimateurs pour $x = 0.5$ (colonne de gauche) et $x = 0.8$ (colonne de droite).
3. Effectuer sur les simulations une comparaison statistique des 3 estimateurs en utilisant le critère de l’erreur quadratique moyenne (Mean Squared Error MSE dans l’article).

Vous utiliserez pour les calculs les 3 fonctions noyaux K :

- Noyau Epanechnikov :

$$K(x) = \frac{3}{4}(1 - x^2) \mathbf{1}(|x| \leq 1).$$

- Noyau quadratique :

$$K(x) = \frac{15}{16}(1 - x^2)^2 \mathbf{1}(|x| \leq 1).$$

- Noyau Gaussien :

$$K(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}x^2\right).$$

où

$$\mathbf{1}(|x| \leq 1) = \begin{cases} 1 & \text{si } |x| \leq 1, \\ 0 & \text{sinon.} \end{cases}$$

Pour choisir la taille de la fenêtre $h_n = n^{-\alpha}$, vous utiliserez la méthode de la validation croisée qui consiste à minimiser la fonction :

$$CV(\alpha) = \frac{1}{n} \sum_{k=1}^n \left(\hat{f}_{(-k)}^*(X_k) - f'(X_k) \right)^2$$

avec, pour $k \in \{0, 1, \dots, n\}$, $\hat{f}_{(-k)}^*(X_k)$ désignant l’estimateur $\hat{f}'_n(X_k)$, $\tilde{f}'_n(X_k)$ ou $\check{f}'_n(X_k)$ de $f'(X_k)$ déterminé par suppression du couple (X_k, Y_k) dans l’échantillon $(X_1, Y_1), \dots, (X_n, Y_n)$.